

CONTACT

Nanterre (92000)
Île-de-France

marcsmouthoud@gmail.com

+33 7 59 37 94 68

linkedin.com/in/stewmthd

github.com/majin-m

Portfolio en ligne

COMPÉTENCES

Ingestion

Open data API

Web scraping

Contrôle d'intégrité Parquet

Transformation & modélisation

ETL / ELT dbt

Architecture médaille

Modèle en étoile MERISE

Qualité & documentation

Tests dbt Contrôles SQL

Dictionnaire de données

Orchestration & déploiement

GitHub Actions Git Docker

Linux

Langages

SQL Python JavaScript

PHP

Bases de données

SQL Server DuckDB MySQL

MongoDB

Bibliothèques & restitution

Pandas NumPy scikit-learn

FastAPI Streamlit Tableau

En cours d'approfondissement

Airflow Spark Databricks

AWS Azure

SOFT SKILLS

Esprit d'équipe · Autonomie ·
Rigueur · Communication ·
Curiosité technique · Organisation

Marc Steven MOUTHOU

DATA ENGINEER

Portfolio : [portfolio-data-lovat.vercel.app](#) · projets, pipelines et données en ligne

PROFIL

En Master Data Engineering & Cloud Computing à aivancity, je conçois des pipelines de données de bout en bout : ingestion de sources brutes, modélisation en couches, tests de qualité et mise à disposition des données. **Je recherche une alternance de 24 mois en Data Engineering à partir de septembre 2026** (3 semaines en entreprise / 1 semaine de cours).

EXPÉRIENCE

Data Manager — Cabinet PENA

Oct. 2024 – Avr. 2025 · 7 mois · Pointe-Noire, Congo

Python · SQL Server · Tableau · Excel

- Centralisation des données d'un cabinet d'avocats, jusque-là sur Excel et en dossiers papier, dans une base SQL Server conçue et déployée pour l'occasion.
- Pipeline Python de nettoyage et de préparation des données, chargement par BULK INSERT.
- Restitutions Tableau ; documentation : dictionnaire de données, conventions de nommage.

PROJETS

Prix des carburants · pipeline quotidien

Python · dbt · DuckDB · GitHub Actions

- Chaque matin, ingestion automatisée des prix officiels de **10 112 stations** : archive contrôlée par empreinte sha256, XML lu en flux, couche brute en Parquet.
- Historisation : **9,5 M relevés** réduits à **5,2 M vrais changements de prix** (LAG, QUALIFY).
- 53 tests dbt** ; les données ne sont publiées que si tous passent. Elles alimentent une recherche de la station la moins chère autour de soi.

Prénoms de France · 126 ans de naissances

Python · dbt · DuckDB

- Ingestion traçable du fichier INSEE (**6,6 M lignes**, 1900–2025) : empreinte et schéma contrôlés à chaque exécution.
- Modèle en couches raw / staging / marts, **39 tests de qualité**, **724 645 lignes** de séries exportées vers une application web.

Entrepôt de données ventes · CRM + ERP

SQL Server · T-SQL · Draw.io

- 6 sources CSV consolidées en architecture médaille : bronze (**116 292 lignes**, BULK INSERT), silver nettoyé par procédures T-SQL, gold en étoile.
- Modèle dimensionnel de **60 398 lignes de faits** et 2 dimensions, vues de reporting, documenté sous Draw.io.

Inclusion financière · Afrique de l'Est

Python · Pandas · scikit-learn · Streamlit

- 23 524 réponses** d'enquête sur 4 pays : analyse exploratoire, traitement des valeurs manquantes, modèle Random Forest (**AUC 0,81**) servi dans une application Streamlit.

FORMATION

Master Data Engineering & Cloud Computing — aivancity

2026 – 2028 · 2 ans

RNCP 37763 · bac+5 · pipelines multi-sources, traitement distribué, cloud AWS / Azure.

Bachelor Concepteur Développeur d'Applications — Scholia

2025 – 2026 · 1 an

RNCP 37873 · bac+3 · applications en couches, versionnement, déploiement DevOps.

The Data Science Bootcamp — GOMYCODE

2023 – 2024 · 8 mois · Dakar

Python, SQL, entreposage OLAP / OLTP, Pandas, analyse exploratoire, Tableau, machine learning.

Data Manager Certificate — Dakar Institute of Technology

2023 · 5 mois · Dakar

SQL avancé, NumPy / Pandas, web scraping (BeautifulSoup, API), ETL, data warehouse sur GCP, Git.

Bachelor Informatique de Gestion, génie logiciel — IAM

2019 – 2022 · 3 ans · Dakar

Développement, systèmes et réseaux, Linux et Windows Server, SQL Server, MERISE.